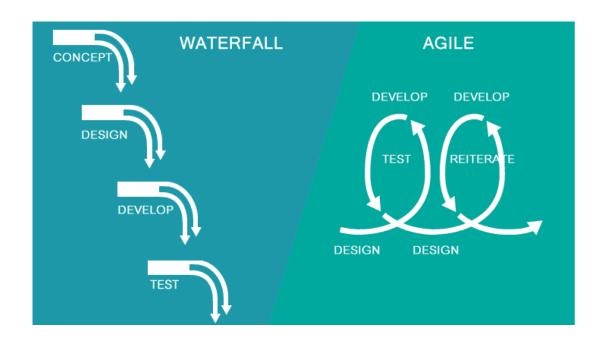
CI/CD для ML

Гущин Александр DMIA Production ML 🚀 весна 2021 Мы уже выяснили, что есть разные подходы к разработке продукта. Подходы с частыми итерациями предполагают регулярное обновление кода, работающего в production.



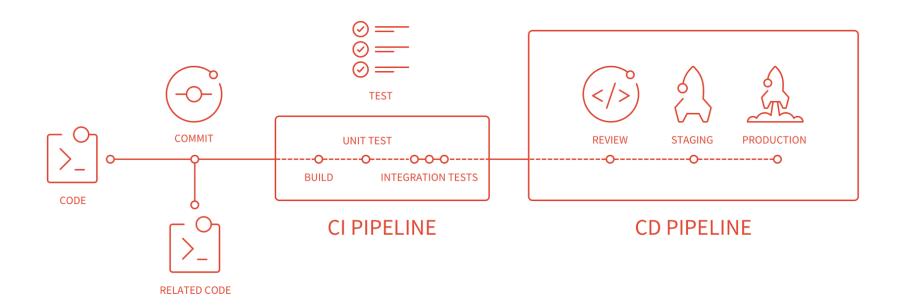
https://blog.planview.com/waterfall-or-agile/

Для этого придуманы практики под названиями:

- CI Continious Integration
- CD Continious Delivery (or Deployment)

Цель этих практик - сократить разрыв между разработкой приложений и управлением их работой с помощью **автоматизации** сборки, тестирования и деплоя. CI/CD является основой DevOps практик.

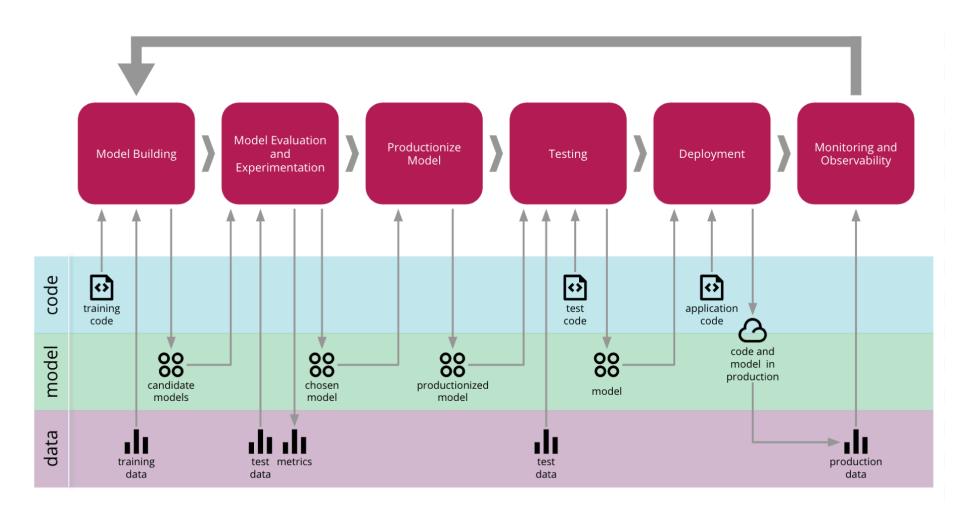
Представим, что мы разрабатываем обычное приложение, без ML. Тогда наш CI/CD может выглядеть так:



Иногда отдельно выделяют Continious Testing, Continious Monitoring.

https://forge.etsi.org/rep/help/ci/README.md

Вместе с ML мы имеем такие этапы нашего пайплайна

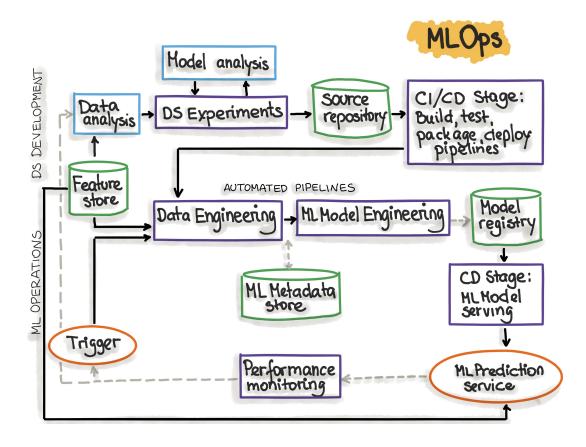


https://martinfowler.com/articles/cd4ml.html

ML and other software systems are similar in continuous integration of source control, unit testing, integration testing, and continuous delivery of the software module or the package. However, in ML, there are a few notable differences:

- Cl is no longer only about testing and validating code and components, but also testing and validating data, data schemas, and models.
- CD is no longer about a single software package or a service, but a system (an ML training pipeline) that should automatically deploy another service (model prediction service).
- CT is a new property, unique to ML systems, that's concerned with automatically retraining and serving the models.

Вместе с ML наш CI/CD должен быть похож на



https://ml-ops.org/content/mlops-principles https://cloud.google.com/solutions/machine-learning/mlops-continuousdelivery-and-automation-pipelines-in-machine-learning

Возможный CI/CD для Шляпы

Стадии выполняются одна за другой.

Continious X	Stage	Triggered by
CI for pipeline	test pipeline	pipeline change
CI for pipeline	build pipeline	
СТ	run pipeline	schedule run
СТ	update model	
CI for api	test api	api change
CI for api	build api	
CD for api	deploy api	

Continious Integration

На этом этапе мы обычно:

- запускаем тесты на ML Pipeline
- готовим ML Pipeline для деплоймента, например, пакуем в контейнер
- запускаем тесты на ML API
- готовим ML API для деплоймента

Continious Delivery (Deployment)

На этом этапе мы обычно:

- разворачиваем / настраиваем инфраструктуру для деплоев
- деплоим ML Pipeline
- деплоим ML API

Continious Training

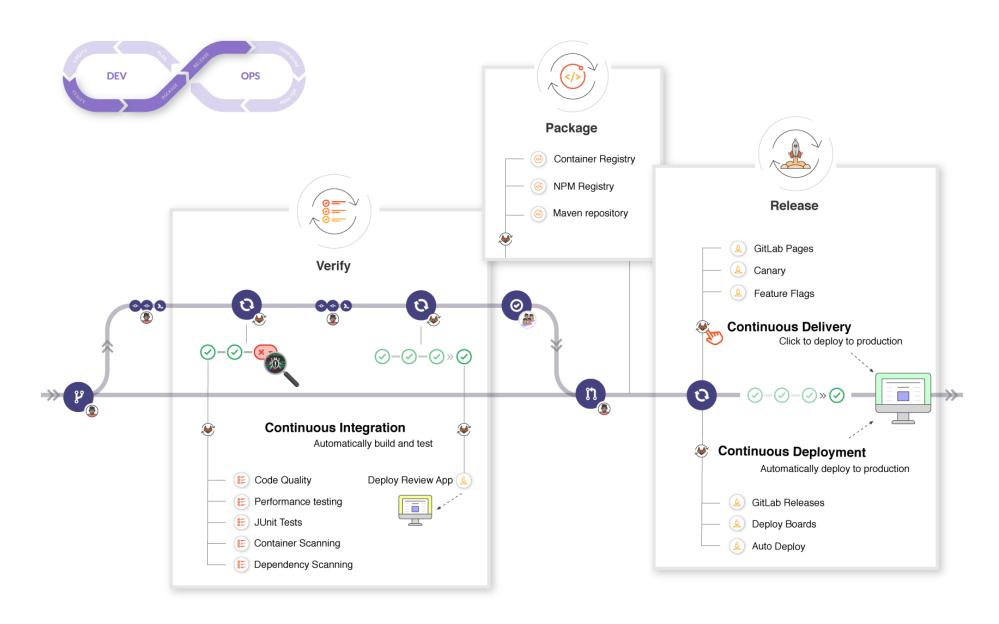
На этом этапе мы запускаем ML Pipeline:

- подтягиваем свежие данные, валидируем их и подготавливаем для обучения
- переобучаем модель, ищем оптимальные гиперпараметры
- сохраняем метрики и артефакты
- принимаем решение об обновлении модели в проде и, при необходимости, триггерим выполнение CI/CD для арі

Инструменты для CI/CD

- Их огромное количество. Одни из наиболее популярных: Jenkins, Circle CI, Gitlab CI, Teamcity, Travis CI...
- Не так важно, какой инструмент выбрать для CI/CD, главное использовать его.
- Хорошая идея реализовать "пустой" пайплайн, а потом заполнить его настоящим кодом.

Gitlab CI/CD



Файл gitlab-ci yml в корне репозитория

Что происходит

Создается и выполняется граф



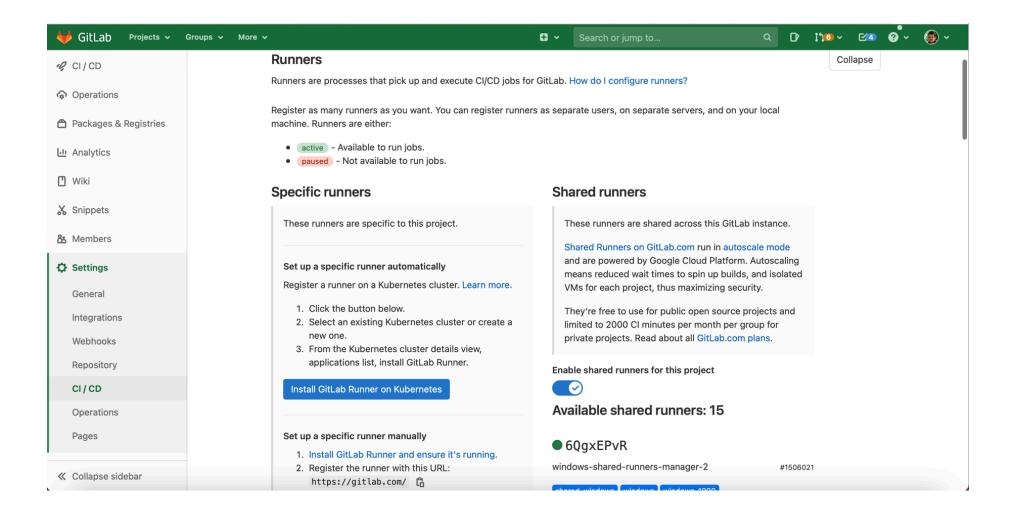
Каждая джоба выполняется в контейнере на сервере с Gitlab runner

Gitlab Runner --> Container --> Job

Есть разные способы организации пайплайнов:

https://docs.gitlab.com/ee/ci/pipelines/pipeline_architectures.html

Gitlab Runners



Артефакты

Передаем между джобами

```
image: python:latest

pages:
script:
- pip install sphinx sphinx-rtd-theme
- cd doc; make html
- mv build/html/ ../public/
artifacts:
paths:
- public
only:
- master
```

https://gitlab.com/gitlab-org/gitlab/-/blob/master/lib/gitlab/ci/templates/Python.gitlab-ci.yml

Кэш

```
# Change pip's cache directory to be inside the project directory since we can
    # only cache local items.
    variables:
       PIP CACHE DIR: "$CI PROJECT DIR/.cache/pip"
    # Pip's cache doesn't store the python packages
    # https://pip.pypa.io/en/stable/reference/pip install/#caching
    # If you want to also cache the installed packages, you have to install
    # them in a virtualenv and cache it as well.
10
11
     cache:
12
      paths:
        - .cache/pip
13
         - venv/
```

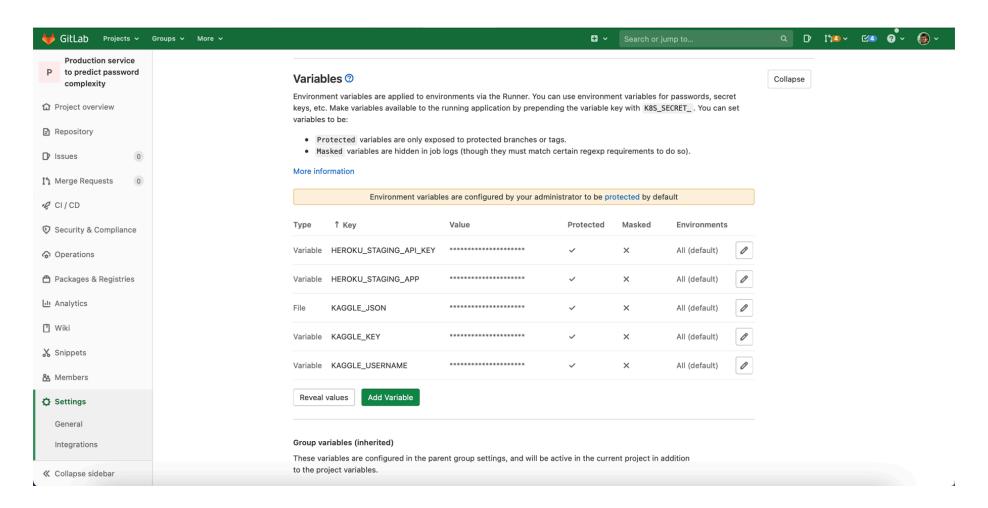
https://docs.gitlab.com/ee/ci/caching/#caching-python-dependencies

before_script

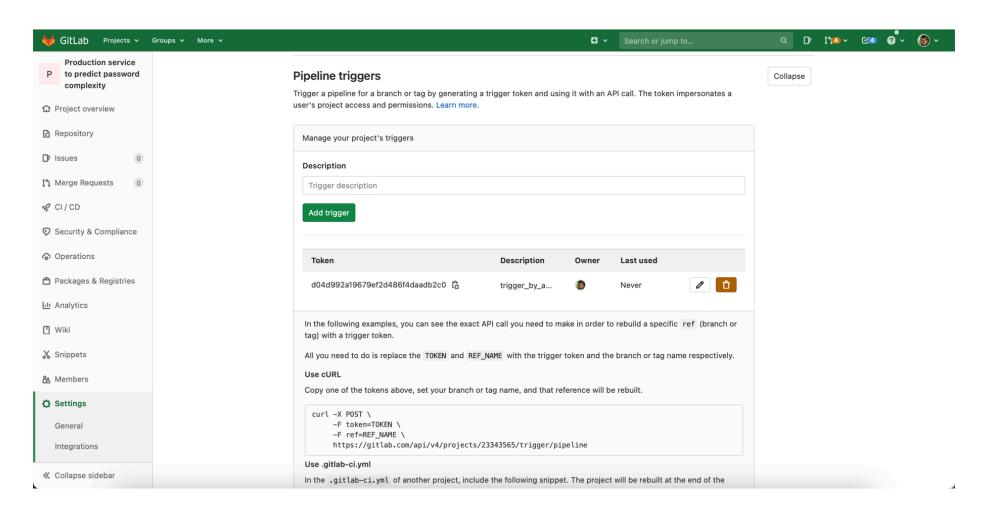
```
before_script:
    - python -V # Print out python version for debugging
    - pip install virtualenv
    - virtualenv venv
    - source venv/bin/activate
```

https://docs.gitlab.com/ee/ci/yaml/#before_script

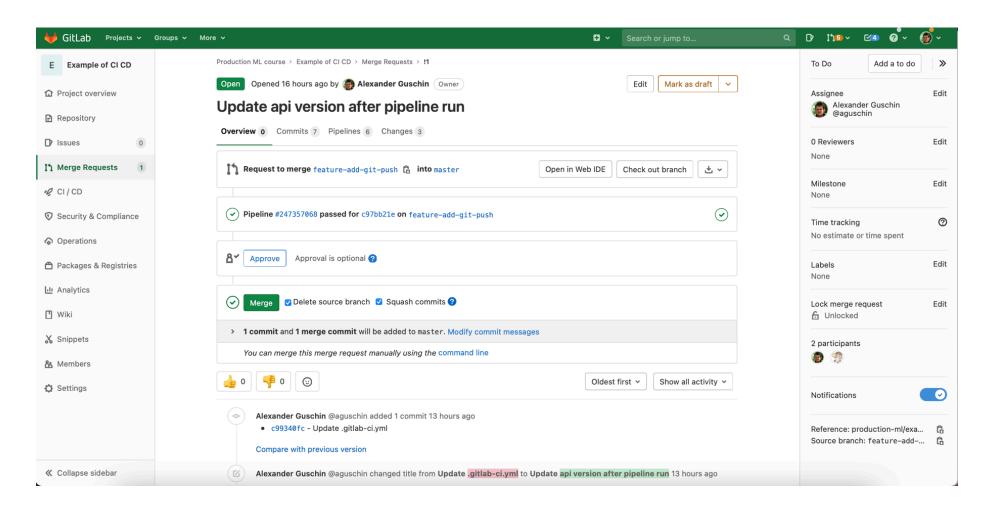
Переменные окружения



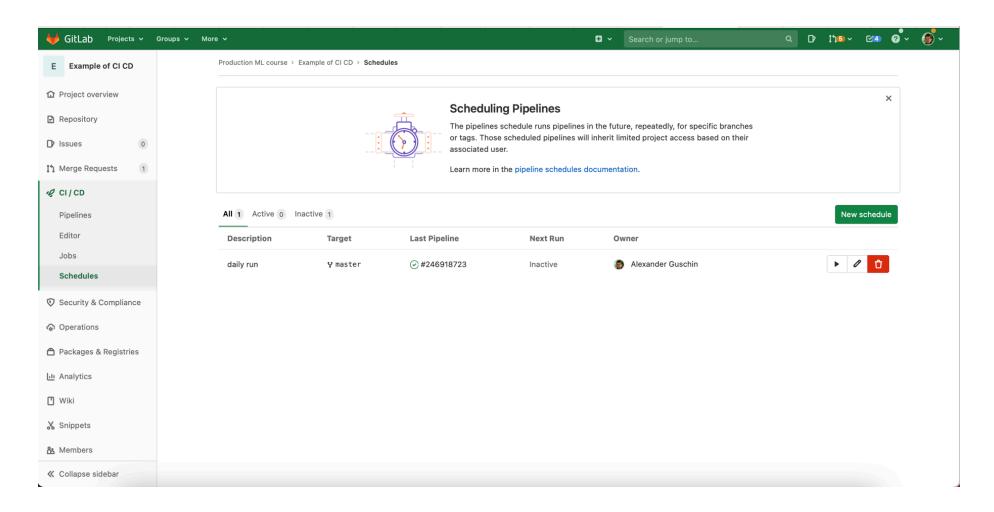
Запуск пайплайна с помощью webhook



Merge requests



Запуск по расписанию



Local debug. Способ 1:

```
# Запускаем bash в контейнере локально
# и воспроизводим шаги из секции "script"

docker run -ti python:latest bash
# if you want to save changes in container,

# find your container id

docker ps --all
# and create new image

docker commit 21cc648e3f7b python:mychanges

# now you can run it with all changes already applied

docker run -ti python:mychanges
```

Local debug. Способ 2:

```
# 1. Устанавливаем gitlab-runner локально. Например, для MacOS:
sudo curl --output /usr/local/bin/gitlab-runner "https://gitlab-runner-downloads.s3.ama
sudo chmod +x /usr/local/bin/gitlab-runner
# 2. Заходим в наш репозиторий
cd passwords-complexity
# 3. Запускаем джобу
gitlab-runner exec docker my-job-name
```

Сам дебаг

```
# 1. Перед ошибкой добавляем в .gitlab-ci.yml "sleep 1000"
vim .gitlab-ci.yml
# 2. Запускаем джобу
gitlab-runner exec docker my-job-name
# 3. В соседнем терминале ищем нужный docker container
docker ps
# 4. Заходим в нужный контейнер и выполняем дебаг
docker exec -ti $CONTAINER_ID bash
```

https://www.lullabot.com/articles/debugging-jobs-gitlab-ci

Local debug. Способ 2:

Нужно иметь в виду:

- 1. Перед запуском изменения нужно коммитить (пушить не обязательно)
- 2. Выполнение идет локально, поэтому variables из репозитория недоступны
- 3. Можно зарегистировать gitlab-runner и запускать на нем CI/CD с gitlab.com
- 4. Раннеры отличаются друг от друга

https://docs.gitlab.com/runner/install/

Саммари

- 1. Continious Integration включает в себя этапы тестирования и сборки приложения.
- 2. Continious Delivery (Deployment) включает в себя этапы настройки окружений и деплоя в них.
- 3. Цель CI/CD сократить разрыв между разработкой приложений и управлением их работой с помощью автоматизации процессов.
- 4. Не так важно, какой инструмент выбрать для CI/CD, главное использовать его.
- 5. Для одного и того же проекта можно собирать разные пайплайны CI/CD выбирайте наиболее простой вариант.
- 6. Используйте локальный дебаг

https://sean-bradley.medium.com/auto-devops-with-gitlab-ci-and-docker-compose-f931233f080f

A walkthrough of how to deploy your app from GitLab using Docker Compose https://medium.com/@vitalypanukhin/docker-compose-and-gitlab-b209d09210f6

Simple continuous deployment with docker compose, docker machine and Gitlab CI

https://medium.com/@Empanado/simple-continuous-deployment-with-docker-compose-docker-machine-and-gitlab-ci-9047765322e1

A tool for local debug of Github CI https://github.com/nektos/act

Семинар

- 1. Смотрим на все этапы на графе выполнения пайплайна проговариваем какие этапы есть в принципе. Смотрим на CI/CD файл в репозитории, обсуждаем первые пару джобов про тестирование и билд докер-образа
- 2. Запускаем первые джобы локально, показываем, как делать локальный дебаг
- 3. Обсуждаем следующие джобы про train model и update-if-qualified. Обсуждаем реализацию обновления модели с пушом в репозиторий.
- 4. Обсуждаем запуск следующей части пайплайна и джобы для передеплоя.
- 5. Обсуждаем варианты, как можно было бы сделать пайплайн иначе.
- 6. Обсуждаем типичные ошибки, которые были при пайплайне, мотивируем использовать локальный дебаг.
- 7. Обсуждаем что потребуется изменить в пайплайне для шляпы.